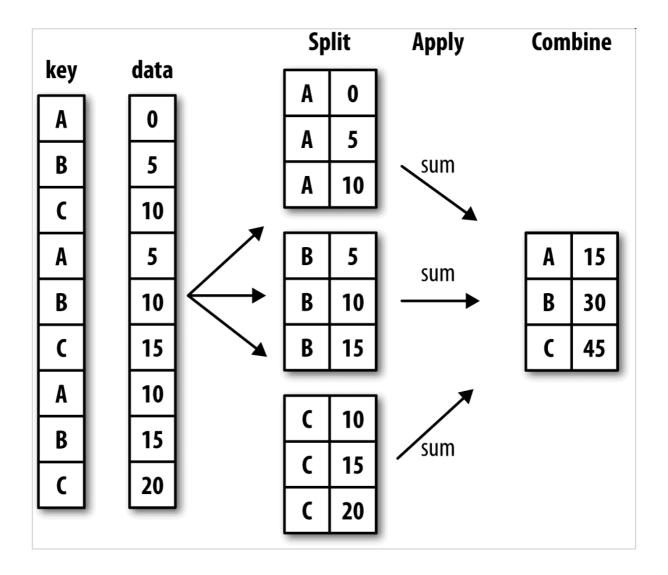
数据分析8数据聚合与分组运算

在将数据集加载、融合、准备好之后,通常就是计算分组统计或生成透视表, pandas提供了一个灵活高效的groupby功能,它使你能以一种自然的方式对数据集进行切片、切块、摘要等操作。

GroupBy机制

分组运算"split-apply-combine"(拆分-应用-合并)。第一个阶段,pandas对象(无论是 Series、DataFrame还是其他的)中的数据会根据你所提供的一个或多个键被拆分(split)为 多组。拆分操作是在对象的特定轴上执行的。例如,DataFrame可以在其行(axis=0)或列(axis=1)上进行分组。然后,将一个函数应用(apply)到各个分组并产生一个新值。最 后,所有这些函数的执行结果会被合并(combine)到最终的结果对象中。



```
In [12]: grouped = df['data1'].groupby(df['key1'])
In [13]: grouped
Out[13]: <pandas.core.groupby.SeriesGroupBy object at 0x7faa31537390>
```

变量grouped是一个GroupBy对象。它实际上还没有进行任何计算,只是含有一些有关分组键df['key1']的中间数据而已

```
In [14]: grouped.mean()
Out[14]:
key1
a  0.746672
b  -0.537585
Name: data1, dtype: float64
```

数据(Series)根据分组键进行了聚合,产生了一个新的Series,其索引为key1列中的唯一值。

一次传入多个数组的列表

```
In [15]: means = df['data1'].groupby([df['key1'], df['key2']]).mean()
In [16]: means
```

```
Out[16]:
key1 key2
a one 0.880536
two 0.478943
b one -0.519439
two -0.555730
Name: data1, dtype: float64
```

```
In [17]: means.unstack()
Out[17]:
key2    one    two
key1
a    0.880536    0.478943
b    -0.519439    -0.555730
```

GroupBy的size方法,它可以返回一个含有分组大小的Series

```
In [23]: df.groupby(['key1', 'key2']).size()
Out[23]:
key1 key2
a    one    2
    two    1
b    one    1
    two    1
dtype: int64
```

对分组进行迭代

GroupBy对象支持迭代,可以产生一组二元元组(由分组名和数据块组成)

```
data1 data2 key1 key2
0 -0.204708 1.393406 a one
1 0.478943 0.092908 a two
4 1.965781 1.246435 a one
b
data1 data2 key1 key2
2 -0.519439 0.281746 b one
3 -0.555730 0.769023 b two
```

对于多重键的情况,元组的第一个元素将会是由键值组成的元组

```
In [25]: for (k1, k2), group in df.groupby(['key1', 'key2']):
  ....: print((k1, k2))
  print(group)
  . . . . :
('a', 'one')
    data1 data2 key1 key2
0 -0.204708 1.393406 a one
4 1.965781 1.246435 a one
('a', 'two')
    data1 data2 key1 key2
1 0.478943 0.092908 a two
('b', 'one')
     data1 data2 key1 key2
2 -0.519439 0.281746 b one
('b', 'two')
   data1 data2 key1 key2
3 -0.55573 0.769023 b two
```

可以将这些数据片段做成一个字典

```
3 -0.555730 0.769023 b two
```

可以根据dtype对列进行分组

```
In [28]: df.dtypes
Out[28]:
data1   float64
data2   float64
key1   object
key2   object
dtype: object
In [29]: grouped = df.groupby(df.dtypes, axis=1)
```

```
In [30]: for dtype, group in grouped:
  ....: print(dtype)
  ...: print(group)
  ....:
float64
     data1 data2
0 -0.204708 1.393406
1 0.478943 0.092908
2 -0.519439 0.281746
3 -0.555730 0.769023
4 1.965781 1.246435
object
 key1 key2
0 a one
  a two
2 b one
3 b two
4
  a one
```

选取一列或列的子集

```
df.groupby('key1')['data1']
df.groupby('key1')[['data2']]
```

```
for name, data in df.groupby('key1')['data1']:
    print(name)
    print(data)
```

对于大数据集,很可能只需要对部分列进行聚合,只需计算data2列的平均值并以DataFrame 形式得到结果

通过字典或Series进行分组

```
Jim 0.124121 0.302614 0.523772 0.000940 1.343810
Travis -0.713544 -0.831154 -2.370232 -1.860761 -0.860757
```

Series也有同样的功能

```
In [41]: map_series = pd.Series(mapping)
In [42]: map_series
Out[42]:
     red
b red
С
     blue
     blue
d
     red
e
f orange
dtype: object
In [43]: people.groupby(map_series, axis=1).count()
Out[43]:
       blue red
```

```
      Joe
      2
      3

      Steve
      2
      3

      Wes
      1
      2

      Jim
      2
      3

      Travis
      2
      3
```

通过函数进行分组

使用Python函数是一种更原生的方法定义分组映射。任何被当做分组键的函数都会在各个索引值上被调用一次,其返回值就会被用作分组名称。

计算一个字符串长度的数组,更简单的方法是传入len函数

根据索引级别分组

层次化索引数据集最方便的地方就在于它能够根据轴索引的一个级别进行聚合

```
In [47]: columns = pd.MultiIndex.from_arrays([['US', 'US', 'US', 'JP', 'JP'],
                                         [1, 3, 5, 1, 3]],
                                         names=['cty', 'tenor'])
   ....:
In [48]: hier df = pd.DataFrame(np.random.randn(4, 5), columns=columns)
In [49]: hier_df
Out[49]:
cty
          US
                                       JΡ
           1
                3 5
                                      1 3
tenor
     0.560145 -1.265934 0.119827 -1.063512 0.332883
     -2.359419 -0.199543 -1.541996 -0.970736 -1.307030
1
2
     0.286350 0.377984 -0.753887 0.331286 1.349742
     0.069877 0.246674 -0.011862 1.004812 1.327195
```

要根据级别分组,使用level关键字传递级别序号或名字

```
In [50]: hier_df.groupby(level='cty', axis=1).count()
Out[50]:
cty JP US
0    2    3
1    2    3
2    2    3
3    2    3
```

数据聚合

聚合指的是任何能够从数组产生标量值的数据转换过程,比如mean、count、min以及sum等。

函数名	说明
count	分组中非NA值的数量
sum	非NA值的和
mean	非NA值的平均值
median	非NA值的算术中位数
std 、var	无偏(分母为n-1)标准差和方差
min, max	非NA值的最小值和最大值
prod	非NA值的积
first、last	第一个和最后一个非NA值

使用你自己的聚合函数,只需将其传入aggregate或agg方法即可

面向列的多函数应用

```
In [57]: tips = pd.read_csv('examples/tips.csv')

# Add tip percentage of total bill
In [58]: tips['tip_pct'] = tips['tip'] / tips['total_bill']

In [59]: tips[:6]
Out[59]:
   total_bill tip smoker day time size tip_pct
0   16.99 1.01 No Sun Dinner 2 0.059447
1   10.34 1.66 No Sun Dinner 3 0.160542
2   21.01 3.50 No Sun Dinner 3 0.166587
3   23.68 3.31 No Sun Dinner 2 0.139780
```

```
4 24.59 3.61 No Sun Dinner 4 0.146808
5 25.29 4.71 No Sun Dinner 4 0.186240
```

对不同的列使用不同的聚合函数,或一次应用多个函数

```
In [60]: grouped = tips.groupby(['day', 'smoker'])
In [61]: grouped_pct = grouped['tip_pct']
In [62]: grouped_pct.agg('mean')
Out[62]:
    smoker
day
Fri
     No
            0.151650
     Yes
            0.174783
            0.158048
Sat No
            0.147906
     Yes
Sun No
          0.160113
     Yes
            0.187250
            0.160298
Thur No
     Yes 0.163863
Name: tip_pct, dtype: float64
```

如果传入一组函数或函数名,得到的DataFrame的列就会以相应的函数命名

```
In [63]: grouped_pct.agg(['mean', 'std', peak_to_peak])
Out[63]:
              mean
                      std peak to peak
day smoker
           0.151650 0.028123 0.067349
Fri No
    Yes
         0.174783 0.051293
                              0.159925
          0.158048 0.039767
Sat No
                              0.235193
         0.147906 0.061375
                              0.290095
    Yes
Sun No
         0.160113 0.042347
                              0.193226
    Yes
          0.187250 0.154134
                              0.644685
         0.160298 0.038774
Thur No
                              0.193350
    Yes 0.163863 0.039389
                               0.151240
```

传入的是一个由(name,function)元组组成的列表,则各元组的第一个元素就会被用作DataFrame的列名

```
In [64]: grouped_pct.agg([('foo', 'mean'), ('bar', np.std)])
Out[64]:
               foo
                        bar
day smoker
Fri No
         0.151650 0.028123
    Yes
           0.174783 0.051293
Sat No 0.158048 0.039767
    Yes 0.147906 0.061375
          0.160113 0.042347
Sun No
          0.187250 0.154134
    Yes
Thur No 0.160298 0.038774
    Yes 0.163863 0.039389
```

想要对tip_pct和total_bill列计算三个统计信息

```
In [65]: functions = ['count', 'mean', 'max']
In [66]: result = grouped['tip_pct', 'total_bill'].agg(functions)
In [67]: result
Out[67]:
                                total_bill
          tip_pct
           count mean
                             max count
                                               mean max
day smoker
             4 0.151650 0.187735
                                       4 18.420000 22.75
Fri No
           15 0.174783 0.263480
    Yes
                                     15 16.813333 40.17
            45 0.158048 0.291990
Sat No
                                      45 19.661778 48.33
             42 0.147906 0.325733
                                       42 21.276667 50.81
    Yes
                                       57 20.506667 48.17
            57 0.160113 0.252672
Sun No
    Yes
           19 0.187250 0.710345
                                      19 24.120000 45.35
Thur No
             45 0.160298 0.266312
                                      45 17.113111 41.19
    Yes
             17 0.163863 0.241255
                                       17 19.190588 43.11
```

```
In [68]: result['tip_pct']
Out[68]:
          count
                  mean
                             max
day smoker
Fri No
            4 0.151650 0.187735
    Yes
            15 0.174783 0.263480
Sat No
            45 0.158048 0.291990
    Yes
           42 0.147906 0.325733
Sun No
            57 0.160113 0.252672
    Yes
            19 0.187250 0.710345
Thur No 45 0.160298 0.266312
           17 0.163863 0.241255
    Yes
```

也可以传入带有自定义名称的一组元组

```
In [69]: ftuples = [('Durchschnitt', 'mean'),('Abweichung', np.var)]
In [70]: grouped['tip_pct', 'total_bill'].agg(ftuples)
Out[70]:
              tip_pct
                                 total_bill
          Durchschnitt Abweichung Durchschnitt Abweichung
day smoker
Fri No
            0.151650 0.000791 18.420000 25.596333
            0.174783 0.002631
    Yes
                                 16.813333 82.562438
Sat No
            0.158048 0.001581
                                 19.661778 79.908965
            0.147906 0.003767 21.276667 101.387535
    Yes
Sun No
            0.160113 0.001793 20.506667 66.099980
                                 24.120000 109.046044
            0.187250 0.023757
    Yes
          0.160298 0.001503 17.113111 59.625081
Thur No
    Yes
            0.163863 0.001551 19.190588 69.808518
```

对一个列或不同的列应用不同的函数,具体的办法是向agg传入一个从列名映射到函数的字典

```
Fri No 3.50
                9
   Yes
          4.73
                31
Sat No
          9.00
                 115
    Yes 10.00
                104
Sun No
          6.00
                167
    Yes
          6.50
                 49
Thur No
         6.70 112
   Yes 5.00
                40
In [72]: grouped.agg({'tip_pct' : ['min', 'max', 'mean', 'std'],
                 'size' : 'sum'})
Out[72]:
           tip_pct
                                          size
              min max mean std sum
day smoker
          0.120385 0.187735 0.151650 0.028123 9
Fri No
    Yes
         0.103555 0.263480 0.174783 0.051293 31
Sat No
         0.056797 0.291990 0.158048 0.039767 115
          0.035638 0.325733 0.147906 0.061375 104
    Yes
Sun No
         0.059447 0.252672 0.160113 0.042347 167
   Yes
         0.065660 0.710345 0.187250 0.154134 49
Thur No
         0.072961 0.266312 0.160298 0.038774 112
    Yes
         0.090014 0.241255 0.163863 0.039389 40
```

以"没有行索引"的形式返回聚合数据

```
In [73]: tips.groupby(['day', 'smoker'], as index=False).mean()
Out[73]:
   day smoker total_bill tip size tip_pct
0 Fri
        No 18.420000 2.812500 2.250000 0.151650
1
  Fri
         Yes 16.813333 2.714000 2.066667 0.174783
2
 Sat
        No 19.661778 3.102889 2.555556 0.158048
              21.276667 2.875476 2.476190 0.147906
3
  Sat
       Yes
              20.506667 3.167895 2.929825 0.160113
4
  Sun
        No
5
  Sun
       Yes
              24.120000 3.516842 2.578947 0.187250
              17.113111 2.673778 2.488889 0.160298
6 Thur
        No
7 Thur Yes 19.190588 3.030000 2.352941 0.163863
```

对结果调用reset_index也能得到这种形式的结果。使用as_index=False方法可以避免一些不必要的计算

小费数据集,假设你想要根据分组选出最高的5个tip_pct值。首先,编写一个选取指定列具有最大值的行的函数

```
In [74]: def top(df, n=5, column='tip_pct'):
           return df.sort_values(by=column)[-n:]
In [75]: top(tips, n=6)
Out[75]:
    total_bill tip smoker day time size tip_pct
109
        14.31 4.00
                                        2 0.279525
                     Yes Sat Dinner
183
        23.17 6.50
                     Yes Sun Dinner
                                        4 0.280535
                     No Sat Dinner 2 0.291990
232
       11.61 3.39
67
        3.07 1.00
                   Yes Sat Dinner 1 0.325733
                                        2 0.416667
178
         9.60 4.00
                     Yes Sun Dinner
                     Yes Sun Dinner
         7.25 5.15
172
                                        2 0.710345
```

对smoker分组并用该函数调用apply

```
In [76]: tips.groupby('smoker').apply(top)
Out[76]:
                                        time size tip_pct
           total_bill tip smoker
                                  day
smoker
                              No Thur
               24.71 5.85
                                                 2 0.236746
No
      88
                                        Lunch
                                                 5 0.241663
      185
               20.69 5.00
                                  Sun Dinner
                              No
      51
               10.29 2.60
                                  Sun Dinner
                                                2 0.252672
                              No
                                                 2 0.266312
                7.51 2.00
      149
                              No Thur Lunch
               11.61 3.39
                                                 2 0.291990
      232
                              No
                                  Sat Dinner
Yes
      109
               14.31 4.00
                                  Sat Dinner
                                                2 0.279525
                             Yes
               23.17 6.50
                                                4 0.280535
      183
                             Yes
                                  Sun Dinner
      67
                3.07 1.00
                             Yes
                                  Sat Dinner
                                                1 0.325733
      178
                9.60 4.00
                                                 2 0.416667
                             Yes
                                  Sun Dinner
      172
                7.25 5.15
                                  Sun Dinner
                                                 2 0.710345
                             Yes
```

如果传给apply的函数能够接受其他参数或关键字,则可以将这些内容放在函数名后面一并传入

```
In [77]: tips.groupby(['smoker', 'day']).apply(top, n=1, column='total bill')
Out[77]:
              total_bill
                        tip smoker
                                     day
                                           time size
                                                      tip_pct
smoker day
No
      Fri 94
                  22.75 3.25
                                 No
                                     Fri Dinner
                                                   2 0.142857
                  48.33 9.00
      Sat 212
                                 No
                                     Sat Dinner
                                                   4 0.186220
      Sun 156
                 48.17 5.00
                                     Sun Dinner 6 0.103799
                                 No
     Thur 142
                 41.19 5.00
                               No Thur Lunch
                                                  5 0.121389
     Fri 95
                 40.17 4.73
                                     Fri Dinner
                                                  4 0.117750
Yes
                                Yes
               50.81 10.00
                                     Sat Dinner 3 0.196812
      Sat 170
                                Yes
      Sun 182
                 45.35 3.50
                                     Sun Dinner
                                                 3 0.077178
                                Yes
      Thur 197
                  43.11 5.00
                                Yes Thur Lunch
                                                  4 0.115982
```

禁止分组键

分组键会跟原始对象的索引共同构成结果对象中的层次化索引。将group_keys=False传入groupby即可禁止该效果

```
In [81]: tips.groupby('smoker', group_keys=False).apply(top)
Out[81]:
    total_bill tip smoker day time size tip_pct
88
        24.71 5.85
                                       2 0.236746
                     No Thur Lunch
                     No Sun Dinner 5 0.241663
185
        20.69 5.00
51
       10.29 2.60
                     No Sun Dinner
                                      2 0.252672
                                      2 0.266312
149
        7.51 2.00
                    No Thur Lunch
                    No Sat Dinner 2 0.291990
232
        11.61 3.39
109
       14.31 4.00
                    Yes Sat Dinner
                                      2 0.279525
183
       23.17 6.50
                    Yes Sun Dinner
                                       4 0.280535
                    Yes Sat Dinner
67
        3.07 1.00
                                      1 0.325733
178
       9.60 4.00
                    Yes Sun Dinner
                                       2 0.416667
172
        7.25 5.15
                         Sun Dinner
                                       2 0.710345
                    Yes
```

分位数和桶分析

将数据拆分成多块的工具(比如cut和qcut)。将这些函数跟groupby结合起来,就能非常轻松地实现对数据集的桶(bucket)或分位数(quantile)分析

```
In [82]: frame = pd.DataFrame({'data1': np.random.randn(1000),
                               'data2': np.random.randn(1000)})
   ....:
In [83]: quartiles = pd.cut(frame.data1, 4)
In [84]: quartiles[:10]
Out[84]:
     (-1.23, 0.489]
1 (-2.956, -1.23]
    (-1.23, 0.489]
2
3
     (0.489, 2.208]
4
    (-1.23, 0.489]
     (0.489, 2.208]
5
     (-1.23, 0.489]
6
    (-1.23, 0.489]
7
     (0.489, 2.208]
8
     (0.489, 2.208]
Name: data1, dtype: category
Categories (4, interval[float64]): [(-2.956, -1.23] < (-1.23, 0.489] < (0.489, -1.23]
2.
208] < (2.208, 3.928]]
```

```
data1
(-2.956, -1.23] 95.0 1.670835 -0.039521 -3.399312
(-1.23, 0.489] 598.0 3.260383 -0.002051 -2.989741
(0.489, 2.208] 297.0 2.954439 0.081822 -3.745356
(2.208, 3.928] 10.0 1.765640 0.024750 -1.929776
```

这些都是长度相等的桶。要根据样本分位数得到大小相等的桶,使用qcut即可

```
# Return quantile numbers
In [88]: grouping = pd.qcut(frame.data1, 10, labels=False)
In [89]: grouped = frame.data2.groupby(grouping)
In [90]: grouped.apply(get_stats).unstack()
Out[90]:
      count max mean min
data1
     100.0 1.670835 -0.049902 -3.399312
     100.0 2.628441 0.030989 -1.950098
1
2
     100.0 2.527939 -0.067179 -2.925113
3
     100.0 3.260383 0.065713 -2.315555
4
     100.0 2.074345 -0.111653 -2.047939
5
     100.0 2.184810 0.052130 -2.989741
      100.0 2.458842 -0.021489 -2.223506
6
      100.0 2.954439 -0.026459 -3.056990
7
      100.0 2.735527 0.103406 -3.745356
      100.0 2.377020 0.220122 -2.064111
```

用特定于分组的值填充缺失值

假设需要对不同的分组填充不同的值。一种方法是将数据分组,并使用apply和一个能够对各数据块调用fillna的函数即可。下面是一些有关美国几个州的示例数据,这些州又被分为东部和西部

```
In [95]: states = ['Ohio', 'New York', 'Vermont', 'Florida',
....: 'Oregon', 'Nevada', 'California', 'Idaho']
```

```
In [96]: group_{key} = ['East'] * 4 + ['West'] * 4
In [97]: data = pd.Series(np.random.randn(8), index=states)
In [98]: data
Out[98]:
Ohio
           0.922264
New York -2.153545
Vermont
          -0.365757
Florida
          -0.375842
Oregon 0.329939
Nevada
           0.981994
California 1.105913
     -1.613716
Idaho
dtype: float64
In [99]: data[['Vermont', 'Nevada', 'Idaho']] = np.nan
```

```
In [100]: data
Out[100]:
       0.922264
Ohio
New York -2.153545
Vermont
                 NaN
Florida -0.375842
Oregon 0.329939
Nevada
                 NaN
California 1.105913
Idaho
                 NaN
dtype: float64
In [101]: data.groupby(group_key).mean()
Out[101]:
East -0.535707
West 0.717926
dtype: float64
```

用分组平均值去填充NA值

预定义各组的填充值

```
In [104]: fill_values = {'East': 0.5, 'West': -1}
In [105]: fill_func = lambda g: g.fillna(fill_values[g.name])
In [106]: data.groupby(group_key).apply(fill_func)
Out[106]:
Ohio
           0.922264
New York -2.153545
           0.500000
Vermont
Florida
          -0.375842
Oregon 0.329939
Nevada -1.000000
California 1.105913
Idaho -1.000000
dtype: float64
```

示例: 分组加权平均数和相关系数

可以进行DataFrame的列与列之间或两个Series之间的运算(比如分组加权平均)

```
In [114]: df = pd.DataFrame({'category': ['a', 'a', 'a', 'a',
                                       'b', 'b', 'b', 'b'],
  . . . . . :
                          'data': np.random.randn(8),
  . . . . . :
                          'weights': np.random.rand(8)})
   ....:
In [115]: df
Out[115]:
 category data weights
    a 1.561587 0.957515
1
       a 1.219984 0.347267
2
       a -0.482239 0.581362
3
       a 0.315667 0.217091
      b -0.047852 0.894406
       b -0.454145 0.918564
5
       b -0.556774 0.277825
6
       b 0.253321 0.955905
7
```

用category计算分组加权平均数

```
In [116]: grouped = df.groupby('category')
In [117]: get_wavg = lambda g: np.average(g['data'], weights=g['weights'])
In [118]: grouped.apply(get_wavg)
Out[118]:
category
a    0.811643
b    -0.122262
dtype: float64
```

Yahoo!Finance的数据集,其中含有几只股票和标准普尔500指数(符号SPX)的收盘价

```
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 2214 entries, 2003-01-02 to 2011-10-14
Data columns (total 4 columns):
AAPL 2214 non-null float64
MSFT 2214 non-null float64
MOX
     2214 non-null float64
SPX 2214 non-null float64
dtypes: float64(4)
memory usage: 86.5 KB
In [121]: close_px[-4:]
Out[121]:
            AAPL MSFT XOM
                                 SPX
2011-10-11 400.29 27.00 76.27 1195.54
2011-10-12 402.19 26.96 77.16 1207.25
2011-10-13 408.43 27.18 76.37 1203.66
2011-10-14 422.00 27.27 78.11 1224.58
```

计算一个由日收益率(通过百分数变化计算)与SPX之间的年度相关系数组成的DataFrame。 创建一个函数,用它计算每列和SPX列的成对相关系数

```
In [122]: spx_corr = lambda x: x.corrwith(x['SPX'])
# 计算相邻数字之间的变化率
In [123]: rets = close_px.pct_change().dropna()
```

```
      2007
      0.508118
      0.658770
      0.786264
      1.0

      2008
      0.681434
      0.804626
      0.828303
      1.0

      2009
      0.707103
      0.654902
      0.797921
      1.0

      2010
      0.710105
      0.730118
      0.839057
      1.0

      2011
      0.691931
      0.800996
      0.859975
      1.0
```

计算Apple和Microsoft的年相关系数

```
In [127]: by_year.apply(lambda g: g['AAPL'].corr(g['MSFT']))
Out[127]:
2003     0.480868
2004     0.259024
2005     0.300093
2006     0.161735
2007     0.417738
2008     0.611901
2009     0.432738
2010     0.571946
2011     0.581987
dtype: float64
```

透视表和交叉表

小费数据集,假设我想要根据day和smoker计算分组平均数(pivot_table的默认聚合类型),并将day和smoker放到行上

```
In [130]: tips.pivot_table(index=['day', 'smoker'])
Out[130]:
              size tip tip_pct total_bill
day smoker
         2.250000 2.812500 0.151650
Fri No
                                      18.420000
    Yes
          2.066667 2.714000 0.174783
                                     16.813333
Sat No 2.555556 3.102889 0.158048
                                     19.661778
    Yes
          2.476190 2.875476 0.147906
                                     21.276667
Sun No
          2.929825 3.167895 0.160113
                                     20.506667
    Yes 2.578947 3.516842 0.187250
                                      24.120000
Thur No
         2.488889 2.673778 0.160298 17.113111
```

```
Yes 2.352941 3.030000 0.163863 19.190588
```

只想聚合tip_pct和size,而且想根据time进行分组。我将smoker放到列上,把day放到行上

```
In [131]: tips.pivot_table(['tip_pct', 'size'], index=['time', 'day'],
                       columns='smoker')
Out[131]:
              size
                              tip_pct
smoker
                No
                        Yes No
                                          Yes
time
      day
Dinner Fri 2.000000 2.222222 0.139622 0.165347
      Sat 2.555556 2.476190 0.158048 0.147906
      Sun 2.929825 2.578947 0.160113 0.187250
      Thur 2.000000
                        NaN 0.159744
                                           NaN
Lunch Fri 3.000000 1.833333 0.187735 0.188937
      Thur 2.500000 2.352941 0.160311 0.163863
```

传入margins=True添加分项小计。这将会添加标签为All的行和列,其值对应于单个等级中所有数据的分组统计

```
In [132]: tips.pivot_table(['tip_pct', 'size'], index=['time', 'day'],
                        columns='smoker', margins=True)
  . . . . . :
Out[132]:
               size
                                       tip_pct
                    Yes
                                     No
smoker
                No
                                 All
                                                   Yes
                                                            All
time
     day
Dinner Fri 2.000000 2.222222 2.166667 0.139622 0.165347 0.158916
      Sat 2.555556 2.476190 2.517241 0.158048 0.147906 0.153152
      Sun 2.929825 2.578947 2.842105 0.160113 0.187250 0.166897
      Thur 2.000000
                        NaN 2.000000 0.159744
                                                   NaN 0.159744
Lunch Fri 3.000000 1.833333 2.000000 0.187735 0.188937 0.188765
      Thur 2.500000 2.352941 2.459016 0.160311 0.163863 0.161301
           2.668874 2.408602 2.569672 0.159328 0.163196 0.160803
All
```

```
In [133]: tips.pivot_table('tip_pct', index=['time', 'smoker'], columns='day',
```

```
aggfunc=len, margins=True)
  . . . . . :
Out[133]:
            Fri Sat Sun Thur
                                  All
day
time
     smoker
Dinner No
            3.0 45.0 57.0 1.0 106.0
             9.0 42.0 19.0 NaN 70.0
            1.0 NaN NaN 44.0 45.0
Lunch No
            6.0 NaN NaN 17.0 23.0
     Yes
All
            19.0 87.0 76.0 62.0 244.0
```

交叉表: crosstab

交叉表(cross-tabulation, 简称crosstab)是一种用于计算分组频率的特殊透视表。

```
In [138]: data
Out[138]:
  Sample Nationality Handedness
              USA Right-handed
      2
           Japan Left-handed
1
2
     3
             USA Right-handed
3
      4
            Japan Right-handed
           Japan Left-handed
4
      5
         Japan Right-handed
      6
5
      7
              USA Right-handed
6
7
      8
               USA Left-handed
8
         Japan Right-handed
      10
               USA Right-handed
9
```

根据国籍和用手习惯对这段数据进行统计汇总

```
In [139]: pd.crosstab(data.Nationality, data.Handedness, margins=True)
Out[139]:
Handedness Left-handed Right-handed All
Nationality
Japan 2 3 5
USA 1 4 5
```

All 3 7 10